

Classification bayésienne

L'objectif est de réaliser un classifieur bayésien permettant de **classer** les images de trois espèces de fleurs (ne recopiez pas les images, afin de préserver votre quota). Lancez le script **recup_donnees.m**, qui affiche des images de pensées, d'œillets et de chrysanthèmes. Vous constatez que ces images n'ont pas toutes la même taille.



FIGURE 1 – De gauche à droite : pensée, œillet, chrysanthème.

Exercice 1 - Calcul de la couleur moyenne d'une image

Dans un premier temps, vous allez classer les images selon la couleur moyenne de chaque espèce de fleurs.

Pour cela, les trois niveaux de couleur $(R, V, B) \in [0, 255]^3$, en chaque pixel de chaque image, sont d'abord transformés en **niveaux de couleur normalisés** (r, v, b), qui sont définis de la manière suivante :

$$(r,v,b) = \frac{1}{\max\{1,R+V+B\}} \left(R,V,B\right)$$

Le principal intérêt des niveaux de couleur normalisés est que deux valeurs parmi (r, v, b) permettent de déduire la troisième, puisque r+v+b=1, sauf dans le cas exceptionnel où (r, v, b)=(0,0,0). Une image est donc caractérisée par les moyennes $(\bar{r}, \bar{v}, \bar{b})$, ou plus simplement par (\bar{r}, \bar{v}) , puisque $\bar{r} + \bar{v} + \bar{b} = 1$, c'est-à-dire par un vecteur $\mathbf{x} = (\bar{r}, \bar{v})^{\top} \in \mathbb{R}^2$ que l'on appelle sa **couleur moyenne**. Compte tenu des différences de couleurs moyennes entre les trois espèces de fleurs, on postule que ce vecteur suffira à les distinguer.



Travail à effectuer : Écrivez la fonction moyenne, qui calcule la couleur moyenne d'une image, c'està-dire $\mathbf{x}^{\top} = (\bar{r}, \bar{v})$ dans un vecteur ligne, sans oublier de convertir les niveaux de couleur (R, V, B) au format single (pour manipuler des réels) et de les normaliser. Le script exercice_1.m regroupe dans trois tableaux de données $X_{pensees}$, $X_{oeillets}$ et $X_{chrysanthemes}$ les valeurs moyennes calculées avec la fonction précédente pour chaque groupe d'images. Il affiche ensuite les couleurs moyennes de l'ensemble des images de fleurs sous la forme de trois nuages de points de \mathbb{R}^2 avec trois couleurs et symboles différents.

Question Au regard de cette figure, la couleur moyenne vous semble-t-elle une caractéristique suffisamment discriminante de ces trois espèces de fleurs?

Exercice 2 - Estimation de la vraisemblance de chaque espèce de fleurs

Les trois nuages de points précédents peuvent être modélisés par des lois normales bidimensionnelles. Il est rappelé que la densité de probabilité d'une loi normale s'écrit, en dimension d:

$$p(\mathbf{x}) = \frac{1}{(2\pi)^{d/2} (\det \Sigma)^{1/2}} \exp\left(-\frac{1}{2} (\mathbf{x} - \mu)^{\top} \Sigma^{-1} (\mathbf{x} - \mu)\right)$$
(1)

où:

- μ désigne l'espérance (la moyenne) des vecteurs $\mathbf{x} \in \mathbb{R}^d : \mu = E[\mathbf{x}] = \frac{1}{n} \mathbf{X}^\top \mathbf{1}_n$.
- Σ désigne la matrice de variance/covariance : $\Sigma = E[(\mathbf{x} \mu)(\mathbf{x} \mu)^{\top}] = \frac{1}{n}(\mathbf{X}^c)^{\top}\mathbf{X}^c$.

Dans le cadre bayésien, la vraisemblance de la classe ω_i associée à chaque type de fleur, qui est caractérisée par la moyenne μ_i et la matrice de variance/covariance Σ_i , peut être modélisée par une loi normale analogue à (1):

$$p(\mathbf{x}|\omega_i) = \frac{1}{(2\pi)^{d/2} (\det \Sigma_i)^{1/2}} \exp\left(-\frac{1}{2} (\mathbf{x} - \mu_i)^{\top} \Sigma_i^{-1} (\mathbf{x} - \mu_i)\right), \quad i \in [1, 3]$$

Il faut donc estimer les paramètres μ_i et Σ_i des trois classes correspondant aux trois espèces de fleurs.



Travail à effectuer : Écrivez la fonction estimation_mu_Sigma permettant d'effectuer l'estimation empirique des paramètres d'une loi normale bidimensionnelle (d=2) à partir d'une matrice de données \mathbf{Y}

Le script exercice_2.m estime les paramètres μ_i et Σ_i des trois classes ω_i correspondant aux trois espèces de fleurs, à partir des tableaux de données X_pensees, X_oeillets et X_chrysanthemes, puis superpose la vraisemblance de chaque classe (en perspective 3D) au nuage de points à partir duquel elle a été estimée.

Exercice 3 - Classification d'images de fleurs

Nous souhaitons maintenant prédire à quelle espèce de fleurs une image requête, \mathbf{x} , doit être associée. Comme nous avons utilisé des données étiquetées (chacune des images étant associée à une espèce de fleurs), il s'agit de classification supervisée. Un premier type de classification consiste à affecter à \mathbf{x} la classe ω_i qui maximise la vraisemblance $p(\mathbf{x}|\omega_i)$. Il s'agit alors d'un classifieur par maximum de vraisemblance.

\wedge

Travail à effectuer : Modifiez le script exercice_3.m, de manière à :

- 1. partitionner le plan \mathbb{R}^2 en trois parties correspondant aux trois classes de fleurs,
- 2. les colorier en trois couleurs différentes associées à celles des nuages de points,
- 3. afficher le pourcentage d'images bien classées sur l'ensemble des trois classes.

Par ailleurs, la règle de Bayes donne l'expression suivante de la **probabilité** a **posteriori** $p(\omega_i|\mathbf{x})$, c'est-à-dire de la probabilité pour que la classe ω_i contienne \mathbf{x} :

$$p(\omega_i|\mathbf{x}) = \frac{p(\mathbf{x}|\omega_i) p(\omega_i)}{p(\mathbf{x})}$$
(2)

Il semble naturel d'affecter à \mathbf{x} la classe ω_i qui maximise $p(\omega_i|\mathbf{x})$. Une telle classification est dite par **maximum** a posteriori (MAP). Sachant que le dénominateur $p(\mathbf{x})$ de (2) est indépendant de ω_i , il n'est pas nécessaire de le connaître pour trouver le maximum des $p(\omega_i|\mathbf{x})$. En revanche, il est nécessaire de connaître la **probabilité** a priori $p(\omega_i)$ de chaque classe ω_i , faute de quoi on fait généralement l'hypothèse que les classes sont équiprobables (l'estimateur par maximum a posteriori revient alors à un estimateur par maximum de vraisemblance).



Travail à effectuer : Écrivez une variante exercice_3_bis.m du script exercice_3.m où, en jouant sur les probabilités a priori des trois classes que vous ajouterez afin de classifier par maximum a posteriori et vous essaierez de maximiser le pourcentage d'images correctement classées.

Pour aller plus loin (facultatif) - Amélioration du classifieur

Même en jouant sur les probabilités a priori, le classifieur obtenu reste décevant, surtout pour pensées et les œillets. En effet, l'observation attentive des images de ces deux espèces, dont les couleurs moyennes sont similaires, montre qu'elles ne sont pas structurées de la même façon : les pensées sont plus sombres au centre, c'est-à-dire au niveau du pistil, par rapport aux œillets. Cela suggère de ne pas seulement calculer la couleur moyenne des images, mais de scinder chaque image en deux parties complémentaires : le centre C (notion à préciser) et le pourtour P (complémentaire de C).

Écrivez un script exercice_4.m reprenant le principe du classifieur MAP de l'exercice 3, mais utilisant trois caractéristiques au lieu de deux pour décrire une image, à savoir le couple de valeurs (\bar{r}, \bar{v}) calculées sur le pourtour P et la valeur \bar{r} calculée sur le centre C.